



张心意

求职意向：AI 算法/大模型开发

出生年月：2001.08

政治面貌：中共党员

15290646087

zxy09221@163.com

github.com/xinyizhang186

教育背景

- ★ **西安电子科技大学 (211)** 应用统计 / 硕士 2024.09-2027.06
生物信息学方向，主要研究深度学习、生物序列模式识别，学院排名前 20%。
- ★ **安徽理工大学** 应用统计学 / 本科 2020.09-2024.06
主修课程：数学分析、高等代数、数据结构、数据库等，专业排名前 5% (保研)。

科研成果

- ★ **论文题目：** *A Multimodal Framework Using ProtT5 and Structural Features for Neuropeptide Prediction Based on Gated Cross-Attention Mechanism and Multiscale Gated Convolution.* 学生一作
(已发表于 *Journal of Chemical Information and Modeling*, (**SCI**, 中科院二区), 2026)
内容： 利用蛋白质大语言模型 ProtT5 提取语义特征，并结合二级结构特征，通过门控交叉注意力与多尺度门控卷积实现特征的自适应交互，实现更好的预测性能。
- ★ **论文题目：** *Identification of N4-acetylcytidine sites by incorporating TCN and BiGRU based on multi-head cross-attention.* 学生一作
(已发表于 *Computational Biology and Chemistry*, (**SCI**, 中科院三区), 2025)
内容： 构建了一种融合 Transformer 与并行 TCN-BiGRU 的混合深度学习模型，利用多头交叉注意力捕捉跨尺度的深度特征关联，提升了 ac4C 位点的识别精度。

实习经历

华为西安研究所 2026.06-2026.09
AI 模型工程师 | 公共开发部

技术栈： Kubernetes、Docker、Skill、大模型量化 (NVFP4/HiF4)、沙箱

工作内容： 围绕 AI Infra、云原生研发以及大模型推理优化，参与 Kubernetes 自动化分析、运行时性能诊断、AI 漏洞验证及大模型推理量化。

- ★ **Kubernetes 版本分析与自动化 Skill：** 设计 K8s 版本分析及 FeatureGate 变更流水线，融合 Release Blog、KEP、CHANGELOG 与源码数据，自动生成版本分析及特性变更报告；构建证据采集、内容生成、质量校验与审计留痕流程，形成 Agent 可调用的标准化能力。
- ★ **生产级 Go pprof 诊断组件：** 实现基于 runtime/pprof 的自动导出组件，支持内存压力与 SIGUSR2 双触发，兼容 cgroup v1/v2，覆盖 CPU、Heap、Block、Mutex、Goroutine 等类型；完成并发写盘与历史批次清理，29 项测试全部通过。
- ★ **AI 漏洞发现与验证：** 构建 Coordinator/Blackboard 多 Agent 协作流程，结合 AST/SAST、污点分析、PoC 与 Validator 实现端到端验证；将 634 个文件筛选至 98 个重点文件，形成 1592 条候选，并对 6 个指定评测目标完成 6/6 验证，获 **华为 2026 ICT 软件大赛难题赛道一等奖**。
- ★ **大模型推理量化：** 针对 Linear 与 GQA Attention，完成 NVFP4 → HiF4 权重离线量化及激活、Q/K/V 在线动态量化；结合校准数据实现 SmoothQuant、Hadamard 旋转、E6M2 scale 搜索与输出敏感度加权，降低量化后 MatMul/Attention 输出误差。

TCL 工业研究院西安研发中心 2025.07-2025.12
算法实习生

技术栈： Transformer、ASR、RAG、Prompt Engineering

工作内容： 围绕智能语音交互与 ASR 场景，参与训练数据构建、媒资知识库 RAG 系统及热词识别算法研发，负责数据质量控制、检索链路优化与向量模型部署。

- ★ **训练数据构建与标注：** 面向模型训练需求，从数据库抽取并清洗语音数据，制定标注规范与质量验收标准；参与标注平台功能优化，完善数据标注与质量控制流程。
- ★ **媒资知识库 RAG 系统构建：** 参与电视语音交互场景下的媒资实体增强链路设计，针对用户描述模糊、语序混乱及口语化俗称等导致实体识别不准问题，采用“向量召回 + 拼音/文本 BM25 + 规则重排”的多路检索；负责 BGE 向量模型部署，并结合线上 Bad Case 优化召回与重排策略，提升候选召回率与匹配准确性。
- ★ **《一种用于音频识别的数据处理系统》(第一发明人)：** 针对人名、地名及行业术语等专有名词识别准确率不足问题，设计音频声学特征与热词语义特征联合建模，引入门控机制、双向交叉注意力与历史结果融合增强上下文建模，提升模型在噪声环境下的泛化能力。相关专利申请已通过初步审查。

项目经验

科研信息检索与分析 Agent

2026.03-2026.06

技术栈：RAG、ReAct、Tool Calling、Redis、Harness、Ollama

项目内容：面向科研文献检索与论文分析场景，构建双 Agent 科研检索系统，融合 Hybrid RAG、自纠错与自动化评测，实现可追溯的论文检索与证据问答。

- **双 Agent 协作与推理**：Worker Agent 基于 ReAct 完成任务规划、Tool Calling、证据观测与答案生成；Judge Agent 从证据充分性、引用真实性、问题匹配度及拒答正确性等维度进行评估，并在未通过时反馈 Worker 重写检索词迭代检索，形成自我纠错闭环，降低幻觉与虚假引用。
- **多源检索与 Hybrid RAG**：融合 OpenAlex、Crossref、arXiv 等真实学术数据源，结合 Query Rewrite、多源召回、DOI/标题去重与论文级词法重排；支持开放 PDF 自动下载、pypdf 正文解析与分块入库，结合向量相似度、章节关键词加权完成 Top-K 证据召回，并通过 Tool Registry 暴露 MCP 兼容工具接口。
- **自动化评测**：依托 Ollama 部署 Qwen 驱动 Worker 推理生成与 Judge 评估，LLM 不可用时自动降级为规则路由、API 限流时本地缓存兜底；基于真实论文 DOI 构建测试集，量化评估 Recall、任务成功率、工具选择准确率、拒答准确率及 p50/p95 延迟等指标，结合 Redis 缓存与 SQLAlchemy 持久化运行 Trace。

专业技能

- ★ **编程语言**：熟练使用 Python，掌握 Go、C# 基本语法
- ★ **深度学习**：掌握 CNN、RNN、Transformer 等算法，熟悉 PyTorch、TensorFlow 框架，具备 NLP 与深度学习应用能力
- ★ **数据库**：熟悉 MySQL，掌握 B+Tree 索引原理与 SQL 优化；熟悉 Redis 数据结构、持久化及缓存机制，掌握消息队列、发布订阅等机制
- ★ **大模型**：掌握 LoRA/QLoRA 及 NF4 量化技术；熟悉 RAG、MCP、Skill 大模型应用技术及 Claude Code 等 AI 编程工具
- ★ **工程能力**：熟悉 Linux 常用命令、Git 版本管理工具；CET-6，具备良好的英文文献及技术文档阅读能力

荣誉奖励

竞赛：2026 ICT 软件大赛难题赛道一等奖（3 名）、全国案例大赛西北赛区二等奖、市场调查大赛国家三等奖

荣誉：优秀研究生、安徽省优秀毕业生、优秀共青团员、三好学生称号

奖学金：本科期间获得国家奖学金 1 次、一等奖学金 2 次；研究生期间获得一等奖学金 2 次